ΤΕΧΝΗΤΗ ΝΟΗΜΟΣΥΝΗ

ΕΡΓΑΣΙΑ : 2

Ερώτηση 1:

ΠΡΙΝ

ΜΕΤΑ

Με τις προεπιλεγμένες παραμέτρους (discount=0.9, noise=0.2) η βέλτιστη πολιτική αποφεύγει τη διάσχιση της γέφυρας και οδηγεί τον πράκτορα προς την κοντινή τερματική κατάσταση χαμηλής ανταμοιβής (+1). Ο λόγος είναι ότι το noise εισάγει πιθανότητα λανθασμένης κίνησης, η οποία στη στενή γέφυρα αυξάνει σημαντικά τον κίνδυνο πτώσης στο χάσμα με πολύ αρνητική ανταμοιβή (−100). Έτσι, η αναμενόμενη αξία της διαδρομής προς το υψηλό terminal μειώνεται.

Όταν μειώσαμε το noise σε 0.0 (κρατώντας σταθερό το discount=0.9), η κίνηση έγινε ντετερμινιστική και ο κίνδυνος πτώσης εξαφανίστηκε. Αυτό αύξησε την αναμενόμενη αξία της διαδρομής προς την τερματική κατάσταση υψηλής ανταμοιβής (+10), με αποτέλεσμα η βέλτιστη πολιτική να επιλέγει να διασχίσει τη γέφυρα.

ΖΗΤΟΥΜΕΝΟ 2 ΕΞΗΓΗΣΗ ΠΕΡΙΠΤΟΣΕΩΝ:

Οι 3 παράμετροι επηρεάζουν:

- **discount** → πόσο "νοιάζεται" για το μέλλον
- **noise** → πόσο ρισκάρει
- **livingReward** → αν θέλει να τελειώνει γρήγορα ή να περιφέρεται

1. Προτίμηση στην κοντινή έξοδο (+1), ρισκάροντας τον γκρεμό (-10)

discount = 0.2, noise = 0.0, livingReward = -1.0

→ Με χαμηλό discount ο πράκτορας προτιμά την κοντινή τερματική κατάσταση αντί για τη μακρινή υψηλή ανταμοιβή.
Το αρνητικό livingReward τον ωθεί να τερματίσει γρήγορα, ενώ το μηδενικό noise επιτρέπει ρισκαδόρικη συμπεριφορά κοντά στον γκρεμό.
Έτσι επιλέγει σύντομη διαδρομή προς το κοντινό terminal

2. Προτίμηση στην κοντινή έξοδο (+1), αποφεύγοντας τον γκρεμό (-10)

discount = 0.2, noise = 0.3, livingReward = -1.0

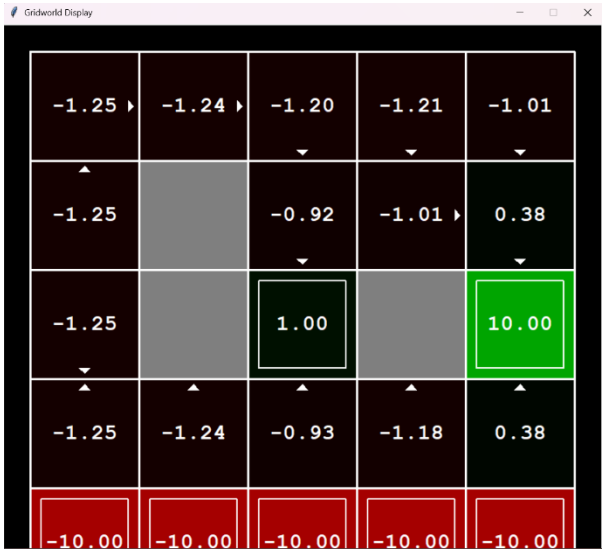

→ Με χαμηλό discount ο πράκτορας προτιμά την κοντινή τερματική κατάσταση.
Το αυξημένο noise καθιστά επικίνδυνη την κίνηση κοντά στον γκρεμό, οπότε η πολιτική επιλέγει ασφαλέστερη διαδρομή μακριά από αυτόν.
Έτσι καταλήγει στο κοντινό terminal με συντηρητική συμπεριφορά

3. Προτίμηση στη μακρινή έξοδο (+10), ρισκάροντας τον γκρεμό (-10)

discount = 0.9, noise = 0.0, livingReward = -0.5

→ Με υψηλό discount ο πράκτορας προτιμά τη μακρινή τερματική κατάσταση υψηλής ανταμοιβής (+10).
Το μηδενικό noise επιτρέπει ρισκαδόρικη κίνηση κοντά στον γκρεμό χωρίς φόβο τυχαίας απόκλισης.
Το αρνητικό livingReward τον ωθεί να επιλέξει πιο σύντομη διαδρομή

4. Προτίμηση στη μακρινή έξοδο (+10), αποφεύγοντας τον γκρεμό (-10)

discount = 0.9, noise = 0.3, livingReward = -0.1

→ Με υψηλό discount ο πράκτορας επιλέγει τη μακρινή τερματική κατάσταση υψηλής ανταμοιβής.
Το αυξημένο noise καθιστά επικίνδυνη την κίνηση κοντά στον γκρεμό, οδηγώντας την πολιτική σε ασφαλή διαδρομή μακριά από αυτόν.
Το μικρό αρνητικό livingReward επιτρέπει την ασφαλή παράκαμψη

5. Αποφυγή και των δύο εξόδων και του γκρεμού (ώστε ένα επεισόδιο να μην τερματίζει ποτέ)

discount = 0.99, noise = 0.0, livingReward = 1.0

→ Με θετικό livingReward, κάθε βήμα παρέχει ανταμοιβή, οπότε ο πράκτορας προτιμά να συνεχίζει να κινείται αντί να τερματίσει σε κάποιο terminal.
Το discount κοντά στο 1 δίνει μεγάλη σημασία στις μελλοντικές ανταμοιβές, ενισχύοντας αυτή τη συμπεριφορά.
Το μηδενικό noise αποτρέπει τυχαίες κινήσεις προς τον γκρεμό ή τις εξόδους

Ερώτηση 2:

ΠΕΙΡΑΜΑ Α: ε = 1

Ο πράκτορας επιλέγει πάντα τυχαίες ενέργειες, οπότε δεν ακολουθεί σταθερή πολιτική βασισμένη στα Q-values. Στα 50 επεισόδια συχνά καταλήγει σε τερματικές καταστάσεις με −100, ενώ μόνο σποραδικά φτάνει στο +1 και πολύ σπάνια στο +10. Η μέση απόδοση είναι πολύ αρνητική , άρα δεν μαθαίνεται αξιόπιστα η βέλτιστη πολιτική μέσα σε 50 επεισόδια

ΠΕΙΡΑΜΑ Α: ε = 0

Ο πράκτορας είναι πλήρως greedy και δεν εξερευνά. Μετά από λίγα αρχικά επεισόδια "κολλάει" στη σίγουρη κοντινή έξοδο +1 (σχεδόν όλα τα επεισόδια από το 3 και μετά τερματίζουν στο +1) και δεν επισκέπτεται ουσιαστικά τη γέφυρα/τη διαδρομή προς το +10 (πολλά states παραμένουν με τιμή 0)

<u>Συμπέρασμα</u>: Σε μόνο 50 επεισόδια δεν υπάρχει σταθερός συνδυασμός ε και learning rate που να κάνει την εκμάθηση της βέλτιστης πολιτικής σχεδόν βέβαιη (>99%), επειδή η επιτυχία εξαρτάται από το αν ο πράκτορας θα εξερευνήσει αρκετά την κρίσιμη διαδρομή της γέφυρας (γεγονός με σημαντική τυχαιότητα)

<u>Ερώτηση 3</u>:

Εκτελώντας τον PacmanQAgent στο mediumGrid παρατηρούμε ότι οι μέσες ανταμοιβές κατά την εκπαίδευση παραμένουν σταθερά αρνητικές (περίπου −515), χωρίς ουσιαστική βελτίωση όσο αυξάνονται τα training episodes. Επιπλέον, στη φάση αξιολόγησης ο πράκτορας χάνει σε όλα τα test παιχνίδια (win rate 0/10), με πολύ αρνητικά σκορ.

Αυτό συμβαίνει επειδή το mediumGrid έχει πολύ μεγαλύτερο χώρο καταστάσεων σε σχέση με το smallGrid. Ο tabular Q-learning agent δεν διαθέτει μηχανισμό γενίκευσης, με αποτέλεσμα κάθε κατάσταση να πρέπει να μαθευτεί ξεχωριστά. Με περιορισμένο αριθμό επεισοδίων, οι περισσότερες καταστάσεις δεν επισκέπτονται αρκετά συχνά ώστε να αποκτήσουν αξιόπιστες Q-values.

Επιπλέον, κατά την εκπαίδευση χρησιμοποιείται epsilon-greedy πολιτική με θετικό ε, γεγονός που οδηγεί σε πολλές τυχαίες κινήσεις. Στο πιο επικίνδυνο περιβάλλον του mediumGrid, αυτές οι κινήσεις αυξάνουν τις συγκρούσεις με φαντάσματα και διατηρούν τις ανταμοιβές σε χαμηλά επίπεδα. Συνεπώς, ο πράκτορας δεν προλαβαίνει να μάθει αποτελεσματική πολιτική μέσα στα 2000 επεισόδια